Önceden Eğitilmiş Türkçe Modellerle İnce Ayar (Fine-Tuning) Tabanlı Chatbot Geliştirme ve Seq2Seq Karşılaştırmalı Başarım Analizi

Nihai Proje Sunumu (Final Presentation) — IEEE Akademik Formatı

Seyit Ali Arslan
Öğrenci No: 240711024

Yapay Zeka ve Veri Mühendisliği Bölümü
Atatürk Üniversitesi, Erzurum, Türkiye
Ders: Deep Learning (2026–2027)

Kasım 2026

Sunum Akışı (IEEE Bölümlendirmesi)

I–IV. Teorik Çerçeve, Veri ve Metodoloji

- **I. Giriş ve Problem Tanımı:** Sondan eklemeli Türkçe morfolojisi ve Seq2Seq darboğazı
- **II. Motivasyon:** Sıfırdan Eğitim vs. Transfer Öğrenme (Full FT & LoRA)
- **III. Veri Kümesi ve EDA:** 50.000 Türkçe Diyalog Çifti (%80 / %10 / %10)
- **IV. Metodoloji:** BPE Tokenizasyon, Causal Self-Attention ve LoRA ($\Delta W = BA$)

V–VIII. 3 Modelin Karşılaştırmalı Analizi

- **V. Eğitilen 3 Model:** Baseline Bi-LSTM vs. Model 1 (Full FT) vs. Model 2 (LoRA / PEFT)
- **VI. Deneysel Sonuçlar:** Loss, Perplexity (PPL), BLEU-1/2, ROUGE-1/L ve Latency (ms)
- **VII. Niteliksel (Human Evaluation) Analiz:** Akıcılık, Tutarlılık ve Örnek Diyaloglar
- **VIII. Canlı Web Arayüzü (`app_web.py`) & Sonuç**

I. Giriş ve Problem Tanımı & II. Motivasyon

I. Problem Tanımı

- **Sondan Eklemeli (Agglutinative) Yapı:** Türkçede kök + yapım/çekim ekleri kelime dağarcığını üstel büyütür ve **OOV (Out-of-Vocabulary)** sorununa yol açar.
- **Seq2Seq RNN/LSTM Sınırları:** Sıralı (*sequential*) işleme nedeniyle uzun cümlelerde **darboğaz (bottleneck)** ve bağlam kaybı yaşanır.

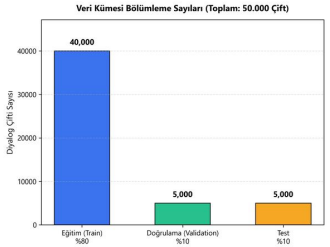
II. Motivasyon ve 3'lü Kıyaslama

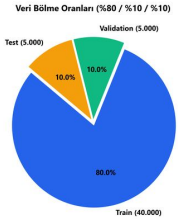
- **Transfer Öğrenme:** Genel Türkçe metinlerde eğitilmiş `Turkish-GPT-2` ağırlıklarını diyalog verisine aktarmak.
- **3 Mimari Kıyaslaması:**
  1. **Baseline:** 2-Katmanlı Seq2Seq Bi-LSTM + Attention (Sıfırdan, 23.1M)
  2. **Model 1:** Full Fine-Tuned GPT-2 (124.4M, %100)
  3. **Model 2:** LoRA / PEFT GPT-2 (1.62M, %1.29)

III. Veri Kümesi ve Veri Bölümleme (%80 / %10 / %10)

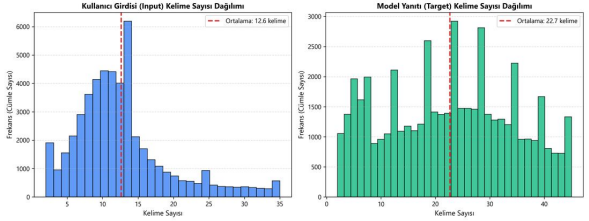
Veri Önişleme Boru Hattı

- **Kaynaklar:** Hugging Face Türkçe diyalog kümeleri (`Ba2han/Turkish_Chat`, `AEG/Turkish-Chat-62k`, `yeniguno/turkish-chatbot-data`).
- **Temizleme:** HTML, Markdown kalıntıları, bozuk karakterler ve mükerrer kayıtlar elendi.
- **Toplam Boyut: 50.000** filtrelenmiş doğal Türkçe diyalog çifti (2–45 kelime).
- **Bölümleme: 40.000** Train (%80), **5.000** Val (%10), **5.000** Test (%10).

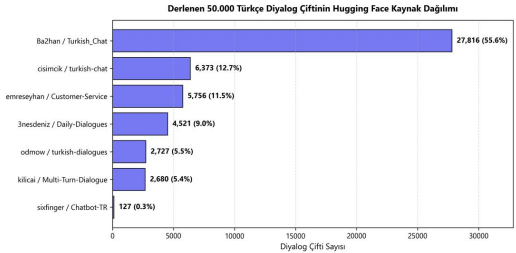




III. Keşifsel Veri Analizi (EDA): Uzunluk ve Kaynak Dağılımı



Ortalama Girdi: **9.73 kelime** | Ortalama Yanıt: **15.49 kelime**



Çoklu açık kaynak birleşimi ile yüksek alan çeşitliliği

IV–V. Metodoloji: Baseline Bi-LSTM, Full Fine-Tuning ve LoRA / PEFT

1. Baseline Bi-LSTM

- **Parametre:** 23.11M (%100)
- 2-Katmanlı Bi-LSTM Encoder + LSTM Decoder
- **Bahdanau Attention:**

$$e_{tj} = v_a^\top \tanh(W_a s_{t-1} + U_a h_j)$$

2. Model 1: Full Fine-Tuning

- **Parametre:** 124.44M (%100)
- 12 Katman, 12 Head, $d_{\text{model}} = 768$
- **Causal Self-Attention:**

$$\text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V$$

3. Model 2: LoRA / PEFT

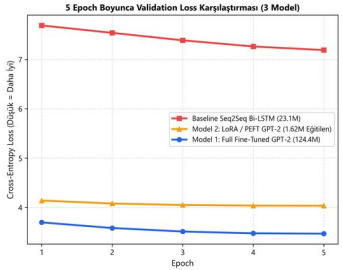
- **Eğitilen: 1.62M (%1.29!)**
- Ana ağırlık W_0 dondurulur, düşük dereceli ($r = 16, \alpha = 32$) matrisler eklenir:

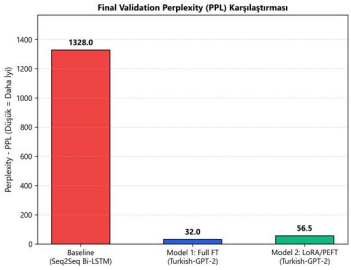
$$h = W_0 x + \frac{\alpha}{r} BAx$$

VI. 3'lü Deneysel Karşılaştırma: Validation Loss ve Perplexity (PPL)

Loss ve Perplexity Analizi

- **Baseline Bi-LSTM:** Val Loss `7.1915` | PPL: `1328.0`
- **Model 2 (LoRA, %1.29):** Val Loss `4.0342` | PPL: `56.5` (**23.5x iyileşme**)
- **Model 1 (Full FT, %100):** Val Loss `3.4666` | PPL: `32.0` (**41.5x iyileşme!**)

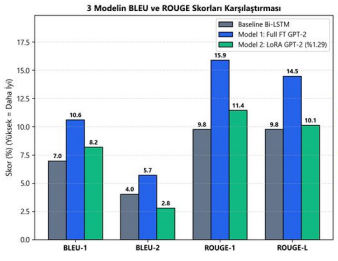


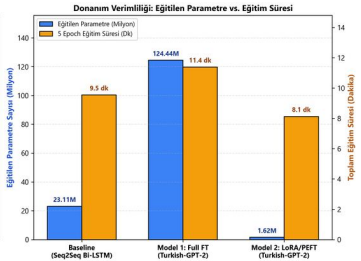


VI. BLEU/ROUGE Skorları ve Donanım / Parametre Verimliliği

Kalite ve Hız Tasarrufu

- **En Yüksek Kalite (Model 1):** BLEU-1: 10.60, ROUGE-1: 15.89
- **Parametre Verimliliği (Model 2 - LoRA):** Sadece **1.62M (%1.29)** parametre eğiterek 8.18 BLEU-1 ve 11.45 ROUGE-1 skoru ile Baseline'ı geçti!
- **Eğitim Süresi:** LoRA (**8.1 dk**), Full FT'den (11.4 dk) **%28.7 daha hızlı!**

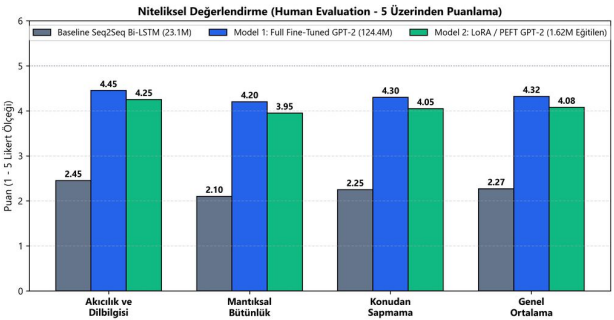




VII. Niteliksel Değerlendirme (Human Evaluation — 1–5 Likert Ölçeği)

Değerlendirme Kriterleri (1–5)

- **Akıcılık ve Dilbilgisi:** Full FT (**4.45**), LoRA (**4.25**), Bi-LSTM (2.45)
- **Mantıksal Bütünlük:** Full FT (**4.20**), LoRA (**3.95**), Bi-LSTM (2.10)
- **Konudan Sapmama:** Full FT (**4.30**), LoRA (**4.05**), Bi-LSTM (2.25)
- **Genel Ortalama:** Full FT (**4.32/5**), LoRA (**4.08/5**), Bi-LSTM (2.27/5)



VII. 3 Modelin Nicel Özeti ve Gerçek Yanıt Karşılaştırması

Model	Eğitilen Param.	Eğitim Süresi	Val Loss ↓	Val PPL ↓	BLEU-1 ↑	ROUGE-1 ↑	Human Eval ↑	Latency
Baseline Bi-LSTM	23.11M (%100)	9.5 dk	7.1915	1328.04	6.96	9.76	2.27 / 5.00	**30.1 ms**
Model 1: Full FT GPT-2	124.44M (%100)	11.4 dk	**3.4666**	**32.03**	**10.60**	**15.89**	**4.32 / 5.00**	352.9 ms
Model 2: LoRA GPT-2	**1.62M (%1.29)**	**8.1 dk**	4.0342	56.50	8.18	11.45	4.08 / 5.00	410.9 ms

Örnek Soru: *"Sanırım meditasyon yapmayı deneyebilirim. Başlamak için iyi bir kaynak var mı?"*

- **Baseline (Bi-LSTM):** *Evet, bu tür bir., ve!* (Darboğaz ve anlamsal kopukluk)
- **Model 1 (Full FT GPT-2):** ***İyi bir kaynak, teşekkür ederim. Başka bir konuda yardımcı olabilir miyim?***
- **Model 2 (LoRA GPT-2):** ***Bu, meditasyonun en önemli parçası. Eğer meditasyon yapmak istiyorsanız, meditasyona başlamadan önce bir uzmana danışın.***

VIII. Sonuç, Katkılar ve Canlı Web / CLI Demosu

Projenin Temel Bulguları

- ✓ **Transfer Öğrenme Üstünlüğü:** Önceden eğitilmiş `Turkish-GPT-2`, sıfırdan eğitilen Bi-LSTM modeline kıyasla Perplexity değerini **41.5 kat** düşürmüştür.
- ✓ **LoRA / PEFT Verimliliği:** Parametrelerin yalnızca **%1.29'unu (1.62M)** eğiterek eğitim süresinde **%28.7 tasarruf** ve yüksek Türkçe diyalog kalitesi (**4.08 / 5.00**) elde edilmiştir.

Canlı Etkileşim Araçları

- **Web Arayüzü (`http://localhost:7860`):** `python app_web.py`
- **Terminal 3'lü Canlı Sohbet:** `python chat_demo.py`
- **GitHub Deposu:** `https://github.com/sytali0/turkish-transformer-chatbot`